

Calculul valorilor proprii și vectorilor proprii prin metodele puterii. Metoda Householder

Cuprins

1	Obiective laborator	1
2	Noțiuni teoretice	1
2.1	Matrice asemenea	1
2.2	Forma Jordan a unei matrice	2
2.3	Determinarea vectorilor și valorilor proprii	2
2.3.1	Metoda puterii directe	2
2.3.2	Metoda puterii inverse	3
2.4	Deflația	4
2.5	Algoritmul PageRank	5
3	Probleme	6

1 Obiective laborator

În urma parcurgerii acestui laborator, studentul va fi capabil să:

- utilizeze metoda puterii directe și metoda puterii inverse pentru a determina valorile și vectorii proprii ale unei matrice;
- aplice metoda deflației pentru a determina valorile și vectorii proprii ale unei matrice;
- aplice proprietățile valorilor și vectorilor proprii în rezolvarea unor probleme.

2 Noțiuni teoretice

Vom începe prin a prezenta conceptul de valoare proprie și vector propriu pentru o matrice pătrată $A \in \mathbb{C}^{n \times n}$. Se numește *valoare proprie* a lui A orice număr complex $\lambda \in \mathbb{C}$ pentru care există un vector nenul $x \in \mathbb{C}^n$ (*vector propriu*), astfel încât

$$Ax = \lambda x$$

Mulțimea tuturor valorilor proprii ale matricei A se numește *spectrul* matricei și se notează cu

$$\lambda(A) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}.$$

Două proprietăți importante ale valorilor proprii ale unei matrice $A \in \mathbb{C}^{n \times n}$ sunt:

- $\sum_{i=1}^n \lambda_i = \text{tr}(A)$, adică suma valorilor proprii este egală cu urma (suma diagonală) a matricei.
- $\prod_{i=1}^n \lambda_i = \det(A)$, adică produsul valorilor proprii este determinantul matricei.

Pentru a determina practic valorile proprii, se consideră polinomul caracteristic $p(\lambda) = \det(\lambda I_n - A)$, iar valorile proprii sunt rădăcinile acestui polinom. Deși acest aspect este esențial din punct de vedere teoretic, în practică se apelează la Metode numerice iterative pentru a determina valorile și vectorii proprii.

2.1 Matrice asemenea

Două matrice $A, B \in \mathbb{C}^{n \times n}$ se numesc *asemenea* dacă există o matrice nesingulară T astfel încât

$$B = T^{-1}AT$$

Ideea de asemănare are la bază simplificarea operațiilor. De exemplu, dacă vrem să rotim un vector din \mathbb{R}^2 în jurul altui vector, putem ca întâi să schimbăm baza astfel încât vectorul de rotație să devină un vector standard (de exemplu, să-l aducem pe axa x), să aplicăm rotația și apoi să schimbăm baza înapoi.

Două matrice asemenea au același spectru.

Demonstrație. Fie $A, B \in \mathbb{C}^{n \times n}$ asemenea, adică $B = T^{-1}AT$. Fie $\lambda \in \mathbb{C}$ o valoare proprie a lui B .

$$\begin{aligned} Bx &= \lambda x \\ T^{-1}ATy &= \lambda x \\ A(Ty) &= \lambda(Ty) \quad \blacksquare \end{aligned}$$

2.2 Forma Jordan a unei matrice

Forma Jordan a unei matrice este o formă canonică care permite simplificarea analizei matricelor, în special în ceea ce privește valorile și vectorii proprii. O matrice A complexă este mereu similară unei matrice bloc-diagonale de forma:

$$J = \begin{bmatrix} J_1 & 0 & \cdots & 0 \\ 0 & J_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & J_k \end{bmatrix}$$

Fiecare bloc se numește *bloc Jordan* și are forma:

$$J_i = \begin{bmatrix} \lambda_i & 1 & 0 & \cdots & 0 \\ 0 & \lambda_i & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_i & 1 \\ 0 & 0 & \cdots & 0 & \lambda_i \end{bmatrix}$$

2.3 Determinarea vectorilor și valorilor proprii

În continuare, vom descrie câteva metode numerice utilizate pentru a determina valorile și vectorii proprii ai unei matrice.

2.3.1 Metoda puterii directe

Fie matricea $A \in \mathbb{R}^{n \times n}$, cu spectrul $\lambda(A) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}$ și vectori proprii normalizați x_1, x_2, \dots, x_n . Fie următoarea presupunere:

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$$

Pentru un vector inițial $y^{(0)} \in \mathbb{R}^n$, care are componentă nenulă pe direcția lui x_1 , metoda puterii directe construiește șirul

$$y^{(k)} = \frac{Ay^{(k-1)}}{\|Ay^{(k-1)}\|}$$

Șirul $y^{(k)}$ converge către vectorul propriu x_1 .

Demonstrație. Fie $P^{-1}AP = J$, unde J este matricea Jordan corespunzătoare lui A . Fie $y^{(0)} = \alpha_1 p_1 + \alpha_2 p_2 + \dots + \alpha_n p_n$, unde $\alpha_1 \neq 0$ și p_i sunt coloanele matricei P .

$$\begin{aligned} y^{(k)} &= \frac{Ay^{(k-1)}}{\|Ay^{(k-1)}\|} = \frac{A^k y^{(0)}}{\|A^k y^{(0)}\|} \\ &= \frac{P^{-1} J^k P \sum_i \alpha_i p_i}{\|P^{-1} J^k P \sum_i \alpha_i p_i\|} \\ &= \frac{P^{-1} J^k \sum_i \alpha_i e_i}{\|P^{-1} J^k \sum_i \alpha_i e_i\|} \end{aligned}$$

Din expresia de mai sus, se dă factor comun forțat pe λ_1 și la numitor dar și la numărător și trecând la limita $k \rightarrow \infty$, ajungem la $y^{(k)} \rightarrow v_1$. Mult mai simplu, dacă A este diagonalizabilă, și $b^{(0)}$ este o combinație

liniară a vectorilor proprii, atunci:

$$\begin{aligned}
 b^{(k)} &= A^k b^{(0)} = A^k \sum_{i=1}^n \alpha_i v_i \\
 &= \sum_{i=1}^n \alpha_i A^k v_i = \sum_{i=1}^n \alpha_i \lambda_i^k v_i \\
 &= \alpha_1 \lambda_1^k (v_1 + \sum_{i=2}^n \frac{\alpha_i}{\alpha_1} \frac{\lambda_i^k}{\lambda_1^k} v_i) \\
 b^{(k)} &\rightarrow \alpha_1 \lambda_1^k v_1 \quad \blacksquare
 \end{aligned}$$

Rata de convergență este dată de $\frac{|\lambda_2|}{|\lambda_1|}$, iar convergența este rapidă dacă $|\lambda_2| \ll |\lambda_1|$.

Algorithm 1 Metoda puterii directe

```

1:  $v \leftarrow$  vectorul initial normalizat
2: for  $i = 1$  to max_iter do
3:    $v_{\text{prev}} \leftarrow v$ 
4:    $v \leftarrow A \cdot v$ 
5:    $v \leftarrow \frac{v}{\|v\|}$ 
6:   if  $\|v - v_{\text{prev}}\| < \text{tol}$  then
7:     break
8:   end if
9: end for
10:  $\lambda \leftarrow v^\top A v$ 

```

2.3.2 Metoda puterii inverse

Metoda puterii inverse aplică ideea puterii directe la matricea $B = A^{-1}$. Valorile proprii ale lui B sunt inversul valorilor proprii ale lui A , deci cea mai mică valoare proprie a lui A corespunde celei mai mari valori proprii ale matricei B . În plus, se poate introduce o deplasare μ , astfel încât $B = (A - \mu I)^{-1}$. Dacă μ se află în apropierea uneia dintre valorile proprii ale lui A , atunci iterația va converge către vectorul propriu asociat lui λ_j , cu $|\lambda_j - \mu|$ minim.

Algorithm 2 Metoda Puterii Inverse

```

1:  $v \leftarrow$  vectorul initial normalizat
2: for  $i = 1$  to max_iter do
3:    $v_{\text{prev}} \leftarrow v$ 
4:   Rezolv  $A \cdot v \leftarrow v_{\text{prev}}$  pentru  $v$ 
5:    $v \leftarrow \frac{v}{\|v\|}$ 
6:   if  $\|v - v_{\text{prev}}\| < \text{tol}$  then
7:     break
8:   end if
9: end for
10:  $\lambda \leftarrow v^\top A v$ 

```

Algorithm 3 Metoda Puterii Inverse cu deplasare

```

1:  $v \leftarrow$  normalized initial vector
2: for  $i = 1$  to  $\text{max\_iter}$  do
3:    $v_{\text{prev}} \leftarrow v$ 
4:   Rezolv  $(A - \mu I) \cdot v = v_{\text{prev}}$  pentru  $v$ 
5:    $v \leftarrow \frac{v}{\|v\|}$ 
6:   if  $\|v - v_{\text{prev}}\| < \text{tol}$  then
7:     break
8:   end if
9: end for
10:  $\lambda \leftarrow v^\top A v$ 

```

Iterarea câtlui Rayleigh. O versiune mult mai eficientă a metodei puterii inverse o constituie *iterarea câtlui Rayleigh* (sau metoda puterii inverse cu deplasare variabilă). Aceasta se aplică matricelor hermitice (simetrice). Pentru o aproximație curentă $x^{(k)}$ a vectorului propriu, se calculează valoarea:

$$\rho^{(k)} = \frac{x^{(k)T} A x^{(k)}}{x^{(k)T} x^{(k)}}.$$

Această mărime, numită *cât Rayleigh*, reprezintă o estimare a valorii proprii asociate lui $x^{(k)}$. Apoi, în pasul următor, se folosește $\mu = \rho^{(k)}$ drept noua deplasare. Cu alte cuvinte, la fiecare iterație:

$$\begin{aligned} y^{(k)} &= (A - \rho^{(k)} I)^{-1} x^{(k)} \\ (A - \rho^{(k)} I) y^{(k)} &= x^{(k)} \\ x^{(k+1)} &= \frac{y^{(k)}}{\|y^{(k)}\|} \end{aligned}$$

Repetând acest procedeu, vectorul și valoarea proprie estimate converg rapid spre vectorul și valoarea reală asociate lui λ_j . Această strategie este extrem de utilă atunci când avem deja un indiciu despre poziția unei valori proprii, întrucât viteza de convergență devine foarte mare după ce $\rho^{(k)}$ se apropie suficient de λ_j . În practică, iterarea câtlui Rayleigh se folosește pe scară largă în algoritmi de diagonalizare numerică și este adesea componenta centrală în metode avansate de calculul valorilor proprii.

Algorithm 4 Iterarea Rayleigh

```

1:  $v \leftarrow \frac{v}{\|v\|}$ 
2: for  $i = 1$  to  $\text{max\_iter}$  do
3:    $v_{\text{prev}} \leftarrow v$ 
4:    $\mu \leftarrow v^\top A v$ 
5:   Rezolv  $(A - \mu I) v = v_{\text{prev}}$  pentru  $v$ 
6:    $v \leftarrow \frac{v}{\|v\|}$ 
7:   if  $\|v - v_{\text{prev}}\| < \text{tol}$  then
8:     break
9:   end if
10: end for
11:  $\lambda \leftarrow v^\top A v$ 

```

2.4 Deflația

Deflația ne permite ca după ce s-a găsit o valoare proprie și un vector propriu asociat, să se “reducă” problema la o submatrice pentru determinarea celorlalte valori proprii.

Fie $\lambda_1, \lambda_2, \dots, \lambda_n$ valorile proprii ale matricei A cu vectorii proprii asociați v_1, v_2, \dots, v_n . Fie x un vector astfel încât $x^T v_1 = 1$. Se consideră matricea:

$$B = A - \lambda_1 v_1 x^T$$

Spectrul matricei B este dat de:

$$\sigma(B) = \{0, \lambda_2, \lambda_3, \dots, \lambda_n\}$$

Cum alegem vectorul x ? O abordare simplă este *deflația Wielandt*:

- Se consideră că am aflat valoarea proprie dominantă λ_1 și vectorul propriu asociat v_1 (de pildă, prin metoda puterii directe).
- Considerăm $x = \frac{1}{\lambda_1 v_i^{(i)}} A_i$. A_i este linia i din matricea A , iar $v_i^{(i)}$ este componenta i a vectorului propriu v_i . Se observă că $x^T c_i = 1$. Construind, matricea B , linia i devine 0.
- Eliminăm linia i și coloana i din matricea B , obținând o matrice de dimensiune $(n-1) \times (n-1)$.

Algorithm 5 MP cu deflație

```

1: eigarray  $\leftarrow$  zero vector of length  $n$ 
2: while size( $A, 1$ )  $> 0$  do
3:    $v \leftarrow$  vector de 1 de lungime size( $A, 1$ )
4:    $v \leftarrow v / \|v\|$ 
5:    $v \leftarrow$  vector obținut din MP
6:    $\lambda \leftarrow v^T A v$ 
7:   eigarray[size( $A, 1$ )]  $\leftarrow \lambda$ 
8:    $y \leftarrow A_{1,:} / (\lambda \cdot v_1)$ 
9:    $A \leftarrow A - \lambda \cdot (v \cdot y)$ 
10:   $A \leftarrow A_{2:\text{end}, 2:\text{end}}$ 
11: end while
```

2.5 Algoritmul PageRank

Matricea Google este un exemplu faimos de matrice stocastică, folosită în *algoritmul PageRank*. Ideea de bază este că fiecare pagină web este un nod, iar legăturile (link-urile) către alte pagini definesc o probabilitate de *tranzitie* de la o pagină la alta. Pentru a rezolva probleme de tip “pagină izolată” sau sub-componente care nu influențează semnificativ restul rețelei, se folosesc tehnici de *deflație*, prin care se separă anumite sub-blocuri ale matricei și se rezolvă problema pe blocuri mai mici.

- **Cum se construiește Matricea Google?** Se consideră că avem n pagini web, notate P_1, P_2, \dots, P_n . Dacă pagina P_i are link-uri către paginile P_j , atunci probabilitatea de a sări din P_i în P_j (prin navigare directă) va fi reprezentată ca un element nenul în matricea noastră. Pentru a asigura că matricea este stocastică (fiecare coloană însumează 1), se normalizează după numărul de link-uri ieșire.
- **Exemplu concret cu $N = 4$ pagini.** Considerăm 4 pagini web: P_1, P_2, P_3, P_4 și următoarea structură de link-uri:

$$P_1 \rightarrow \{P_2, P_3\}, \quad P_2 \rightarrow \{P_3\}, \quad P_3 \rightarrow \{P_1, P_4\}, \quad P_4 \rightarrow \{P_2\}.$$

Matricea de *adiacență* (prin linii) ar putea arăta astfel:

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix}.$$

Pentru a obține *matricea de stocastică* M , fiecare coloană se normalizează la 1.

$$M = \begin{bmatrix} 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 1/2 & 0 & 0 \end{bmatrix}.$$

- **Calculul PageRank.** PageRank-ul este o distribuție de probabilitate care indică importanța fiecărei pagini web. PageRank-ul rămâne neschimbat indiferent de ce face utilizatorul, deci satisface ecuația:

$$MR = R$$

Totuși, există șansa ca utilizatorul să nu continue click-urile. Fie d probabilitatea de a continua să navigheze și $1 - d$ probabilitatea de a sări la o pagină aleatorie. Astfel, definim matricea Google:

$$G = dM + \frac{(1-d)}{N} \text{ONES}(N)$$

PageRank-ul va fi vectorul propriu asociat lui $\lambda = 1$ al matricei Google G . Cum $\lambda = 1$ este și valoare proprie dominantă, se poate aplica metoda puterii.

- **Deflația în PageRank.** Dacă anumite pagini sunt “izolate” sau formează sub-componente, se pot crea blocuri separate pentru care vectorul propriu asociat lui $\lambda = 1$ se calculează ușor, după care aceste blocuri pot fi *deflate* pentru a reduce dimensiunea problemei și, implicit, efortul de calcul.

Algorithm 6 PageRank

```

1:  $n \leftarrow$  number of rows of  $M$ 
2:  $v \leftarrow \mathbf{1}_n$ 
3:  $G \leftarrow d \cdot M + \frac{1-d}{n} \cdot \mathbf{1}_{n \times n}$ 
4: while true do
5:    $v_{\text{prev}} \leftarrow v$ 
6:    $v \leftarrow G \cdot v$ 
7:    $v \leftarrow \frac{v}{\|v\|}$ 
8:   if  $\|v - v_{\text{prev}}\| < \text{tol}$  then
9:     break
10:  end if
11: end while
12:  $v \leftarrow \frac{v}{\|v\|_1}$ 

```

3 Probleme

1. Fie matricea tridiagonală:

$$A = \begin{bmatrix} a_1 & c_1 & \dots & & \\ b_2 & a_2 & c_2 & \dots & \\ \vdots & \vdots & \ddots & \ddots & \\ & & b_{n-1} & a_{n-1} & c_{n-1} \\ & & & b_n & a_n \end{bmatrix}.$$

Se construiește șirul de polinoame:

$$p_0(\lambda) = 1, \quad p_1(\lambda) = \lambda - a_1, \quad p_n(\lambda) = (\lambda - a_n) p_{n-1}(\lambda) - b_n c_{n-1} p_{n-2}(\lambda).$$

1. Arătați că $p_n(\lambda)$ este polinomul caracteristic al matricei A .
2. Scrieți o funcție OCTAVE care calculează valorile și vectorii proprii ale matricei A .
2. Să se demonstreze pentru o matrice $A \in \mathbb{R}^{n \times n}$ proprietățile următoare:

1. $\sigma(A^{-1}) = \left\{ \frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_n} \right\}$;
2. $\sigma(A - \mu I_n) = \{\lambda_i - \mu\}, \forall \mu \in \mathbb{R}$;
3. $\sigma(A^k) = \{\lambda_i^k\}, \forall k \in \mathbb{N}$;
4. $\sigma((A - \mu I_n)^{-1}) = \left\{ \frac{1}{\lambda_i - \mu} \right\}, \forall \mu \in \mathbb{R}$.

3. Calculați valorile și vectorii proprii ai unui reflector Householder.

Indicație: $G^T u = e_1 G$ - este un reflector. Coloanele lui G sunt vectori proprii.

4. Pentru matricea:

$$A = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad c^2 + s^2 = 1,$$

calculați valorile și vectorii proprii.