

Calculul valorilor proprii și vectorilor proprii prin metodele puterii. Metoda Householder

Cuprins

1	Obiective laborator	1
2	Noțiuni teoretice	1
2.1	Matrice asemenea	1
2.2	Forma Jordan a unei matrice	2
2.3	Determinarea vectorilor și valorilor proprii	2
2.3.1	Metoda puterii directe	2
2.3.2	Metoda puterii inverse	3
2.4	Deflația	3
2.5	Algoritmul PageRank	4
3	Probleme	5

1 Obiective laborator

În urma parcurgerii acestui laborator, studentul va fi capabil să:

- utilizeze metoda puterii directe și metoda puterii inverse pentru a determina valorile și vectorii proprii ale unei matrice;
- aplice metoda deflației pentru a determina valorile și vectorii proprii ale unei matrice;
- aplice proprietățile valorilor și vectorilor proprii în rezolvarea unor probleme.

2 Noțiuni teoretice

Vom începe prin a prezenta conceptul de valoare proprie și vector propriu pentru o matrice pătrată $A \in \mathbb{C}^{n \times n}$. Se numește *valoare proprie* a lui A orice număr complex $\lambda \in \mathbb{C}$ pentru care există un vector nenul $x \in \mathbb{C}^n$ (*vector propriu*), astfel încât

$$Ax = \lambda x$$

Mulțimea tuturor valorilor proprii ale matricei A se numește *spectrul* matricei și se notează cu

$$\lambda(A) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}.$$

Două proprietăți importante ale valorilor proprii ale unei matrice $A \in \mathbb{C}^{n \times n}$ sunt:

- $\sum_{i=1}^n \lambda_i = \text{tr}(A)$, adică suma valorilor proprii este egală cu urma (suma diagonală) a matricei.
- $\prod_{i=1}^n \lambda_i = \det(A)$, adică produsul valorilor proprii este determinantul matricei.

Pentru a determina practic valorile proprii, se consideră polinomul caracteristic $p(\lambda) = \det(\lambda I_n - A)$, iar valorile proprii sunt rădăcinile acestui polinom. Deși acest aspect este esențial din punct de vedere teoretic, în practică se apelează la Metode numerice iterative pentru a determina valorile și vectorii proprii.

2.1 Matrice asemenea

Două matrice $A, B \in \mathbb{C}^{n \times n}$ se numesc *asemenea* dacă există o matrice nesingulară T astfel încât

$$B = T^{-1}AT$$

Ideea de asemănare are la bază simplificarea operațiilor. De exemplu, dacă vrem să rotim un vector din \mathbb{R}^2 în jurul altui vector, putem ca întâi să schimbăm baza astfel încât vectorul de rotație să devină un vector standard (de exemplu, să-l aducem pe axa x), să aplicăm rotația și apoi să schimbăm baza înapoi.

Două matrice asemenea au același spectru.

Demonstrație. Fie $A, B \in \mathbb{C}^{n \times n}$ asemenea, adică $B = T^{-1}AT$. Fie $\lambda \in \mathbb{C}$ o valoare proprie a lui B .

$$\begin{aligned} Bx &= \lambda x \\ T^{-1}ATy &= \lambda x \\ A(Ty) &= \lambda(Ty) \quad \blacksquare \end{aligned}$$

2.2 Forma Jordan a unei matrice

Forma Jordan a unei matrice este o formă canonică care permite simplificarea analizei matricelor, în special în ceea ce privește valorile și vectorii proprii. O matrice A complexă este mereu similară unei matrice bloc-diagonale de forma:

$$J = \begin{bmatrix} J_1 & 0 & \cdots & 0 \\ 0 & J_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & J_k \end{bmatrix}$$

Fiecare bloc se numește *bloc Jordan* și are forma:

$$J_i = \begin{bmatrix} \lambda_i & 1 & 0 & \cdots & 0 \\ 0 & \lambda_i & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_i & 1 \\ 0 & 0 & \cdots & 0 & \lambda_i \end{bmatrix}$$

2.3 Determinarea vectorilor și valorilor proprii

În continuare, vom descrie câteva metode numerice utilizate pentru a determina valorile și vectorii proprii ai unei matrice.

2.3.1 Metoda puterii directe

Fie matricea $A \in \mathbb{R}^{n \times n}$, cu spectrul $\lambda(A) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}$ și vectori proprii normalizați x_1, x_2, \dots, x_n . Fie următoarea presupunere:

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|$$

Pentru un vector inițial $y^{(0)} \in \mathbb{R}^n$, care are componentă nenulă pe direcția lui x_1 , metoda puterii directe construiește șirul

$$y^{(k)} = \frac{Ay^{(k-1)}}{\|Ay^{(k-1)}\|}$$

Șirul $y^{(k)}$ converge către vectorul propriu x_1 .

Demonstrație. Fie $P^{-1}AP = J$, unde J este matricea Jordan corespunzătoare lui A . Fie $y^{(0)} = \alpha_1 p_1 + \alpha_2 p_2 + \dots + \alpha_n p_n$, unde $\alpha_1 \neq 0$ și p_i sunt coloanele matricei P .

$$\begin{aligned} y^{(k)} &= \frac{Ay^{(k-1)}}{\|Ay^{(k-1)}\|} = \frac{A^k y^{(0)}}{\|A^k y^{(0)}\|} \\ &= \frac{P^{-1} J^k P \sum_i \alpha_i p_i}{\|P^{-1} J^k P \sum_i \alpha_i p_i\|} \\ &= \frac{P^{-1} J^k \sum_i \alpha_i e_i}{\|P^{-1} J^k \sum_i \alpha_i e_i\|} \end{aligned}$$

Din expresia de mai sus, se dă factor comun forțat pe λ_1 și la numitor dar și la numărător și trecând la limita $k \rightarrow \infty$, ajungem la $y^{(k)} \rightarrow v_1$. Mult mai simplu, dacă A este diagonalizabilă, și $b^{(0)}$ este o combinație

liniară a vectorilor proprii, atunci:

$$\begin{aligned}
 b^{(k)} &= A^k b^{(0)} = A^k \sum_{i=1}^n \alpha_i v_i \\
 &= \sum_{i=1}^n \alpha_i A^k v_i = \sum_{i=1}^n \alpha_i \lambda_i^k v_i \\
 &= \alpha_1 \lambda_1^k (v_1 + \sum_{i=2}^n \frac{\alpha_i}{\alpha_1} \frac{\lambda_i^k}{\lambda_1^k} v_i) \\
 b^{(k)} &\rightarrow \alpha_1 \lambda_1^k v_1 \quad \blacksquare
 \end{aligned}$$

Rata de convergență este dată de $\frac{|\lambda_2|}{|\lambda_1|}$, iar convergența este rapidă dacă $|\lambda_2| \ll |\lambda_1|$.

2.3.2 Metoda puterii inverse

Metoda puterii inverse aplică ideea puterii directe la matricea $B = A^{-1}$. Valorile proprii ale lui B sunt inversul valorilor proprii ale lui A , deci cea mai mică valoare proprie a lui A corespunde celei mai mari valori proprii ale matricei B . În plus, se poate introduce o deplasare μ , astfel încât $B = (A - \mu I)^{-1}$. Dacă μ se află în apropierea uneia dintre valorile proprii ale lui A , atunci iterația va converge către vectorul propriu asociat lui λ_j , cu $|\lambda_j - \mu|$ minim.

Iterarea cântului Rayleigh. O versiune mult mai eficientă a metodei puterii inverse o constituie *iterarea cântului Rayleigh* (sau metoda puterii inverse cu deplasare variabilă). Aceasta se aplică matricelor hermitice (simetrice). Pentru o aproximație curentă $x^{(k)}$ a vectorului propriu, se calculează valoarea:

$$\rho^{(k)} = \frac{x^{(k)T} A x^{(k)}}{x^{(k)T} x^{(k)}}.$$

Această mărime, numită *cânt Rayleigh*, reprezintă o estimare a valorii proprii asociate lui $x^{(k)}$. Apoi, în pasul următor, se folosește $\mu = \rho^{(k)}$ drept noua deplasare. Cu alte cuvinte, la fiecare iterație:

$$\begin{aligned}
 y^{(k)} &= (A - \rho^{(k)} I)^{-1} x^{(k)} \\
 (A - \rho^{(k)} I) y^{(k)} &= x^{(k)} \\
 x^{(k+1)} &= \frac{y^{(k)}}{\|y^{(k)}\|}
 \end{aligned}$$

Repetând acest procedeu, vectorul și valoarea proprie estimate converg rapid spre vectorul și valoarea reală asociate lui λ_j . Această strategie este extrem de utilă atunci când avem deja un indiciu despre poziția unei valori proprii, întrucât viteza de convergență devine foarte mare după ce $\rho^{(k)}$ se apropie suficient de λ_j . În practică, iterarea cântului Rayleigh se folosește pe scară largă în algoritmi de diagonalizare numerică și este adesea componenta centrală în metode avansate de calculul valorilor proprii.

2.4 Deflația

Deflația ne permite ca după ce s-a găsit o valoare proprie și un vector propriu asociat, să se “reducă” problema la o submatrice pentru determinarea celorlalte valori proprii. O abordare simplă este *deflația Wielandt*:

- Se consideră că am aflat valoarea proprie dominantă λ_1 și vectorul propriu asociat x_1 (de pildă, prin metoda puterii directe).
- Se construiește matricea

$$B = (I_n - x_1 y^T)A$$

unde $y \in \mathbb{R}^n$ se alege astfel încât $y^T x_1 = 1$. Se poate arăta că B “blochează” componenta pe direcția x_1 și are valorile proprii $\{0, \lambda_2, \lambda_3, \dots, \lambda_n\}$.

- Apoi se elimină prima linie și prima coloană (corespunzătoare valorii proprii 0), obținându-se o submatrice care își păstrează celelalte valori proprii $\lambda_2, \dots, \lambda_n$. Peste această submatrice, se aplică din nou o metodă (de exemplu, puterea directă) pentru a găsi următoarea valoare proprie.

2.5 Algoritmul PageRank

Matricea Google este un exemplu faimos de matrice stocastică, folosită în *algoritmul PageRank*. Ideea de bază este că fiecare pagină web este un nod, iar legăturile (link-urile) către alte pagini definesc o probabilitate de *tranzitie* de la o pagină la alta. Pentru a rezolva probleme de tip “pagină izolată” sau sub-componente care nu influențează semnificativ restul rețelei, se folosesc tehnici de *deflație*, prin care se separă anumite sub-blocuri ale matricei și se rezolvă problema pe blocuri mai mici.

- **Cum se construiește Matricea Google?** Se consideră că avem n pagini web, notate P_1, P_2, \dots, P_n . Dacă pagina P_i are link-uri către paginile P_j , atunci probabilitatea de a sări din P_i în P_j (prin navigare directă) va fi reprezentată ca un element nenul în matricea noastră. Pentru a asigura că matricea este stocastică (fiecare coloană însumează 1), se normalizează după numărul de link-uri ieșire.
- **Exemplu concret cu $N = 4$ pagini.** Considerăm 4 pagini web: P_1, P_2, P_3, P_4 și următoarea structură de link-uri:

$$P_1 \rightarrow \{P_2, P_3\}, \quad P_2 \rightarrow \{P_3\}, \quad P_3 \rightarrow \{P_1, P_4\}, \quad P_4 \rightarrow \{P_2\}.$$

Matricea de *adiacență* (prin linii) ar putea arăta astfel:

$$A = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix}.$$

Pentru a obține *matricea de stocastică* M , fiecare coloană se normalizează la 1.

$$M = \begin{bmatrix} 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 \\ 1 & 0 & 0 & 1 \\ 0 & 1/2 & 0 & 0 \end{bmatrix}.$$

- **Calculul PageRank.** PageRank-ul este o distribuție de probabilitate care indică importanța fiecărei pagini web. PageRank-ul rămâne neschimbat indiferent de ce face utilizatorul, deci satisface ecuația:

$$MR = R$$

Totuși, există șansa ca utilizatorul să nu continue click-urile. Fie d probabilitatea de a continua să navigheze și $1 - d$ probabilitatea de a sări la o pagină aleatorie. Astfel, definim matricea Google:

$$G = dM + \frac{(1-d)}{N} \text{ONES}(N)$$

PageRank-ul va fi vectorul propriu asociat lui $\lambda = 1$ al matricei Google G . Cum $\lambda = 1$ este și valoare proprie dominantă, se poate aplica metoda puterii.

- **Deflația în PageRank.** Dacă anumite pagini sunt “izolate” sau formează sub-componente, se pot crea blocuri separate pentru care vectorul propriu asociat lui $\lambda = 1$ se calculează ușor, după care aceste blocuri pot fi *deflate* pentru a reduce dimensiunea problemei și, implicit, efortul de calcul.

3 Probleme

1. Fie matricea tridiagonală:

$$A = \begin{bmatrix} a_1 & c_1 & \dots & & \\ b_2 & a_2 & c_2 & \dots & \\ \vdots & \vdots & \ddots & \ddots & \\ & & b_{n-1} & a_{n-1} & c_{n-1} \\ & & & b_n & a_n \end{bmatrix}.$$

Se construiește șirul de polinoame:

$$p_0(\lambda) = 1, \quad p_1(\lambda) = \lambda - a_1, \quad p_n(\lambda) = (\lambda - a_n)p_{n-1}(\lambda) - b_n c_{n-1} p_{n-2}(\lambda).$$

1. Arătați că $p_n(\lambda)$ este polinomul caracteristic al matricei A .
2. Scrieți o funcție OCTAVE care calculează valorile și vectorii proprii ale matricei A .
2. Să se demonstreze pentru o matrice $A \in \mathbb{R}^{n \times n}$ proprietățile următoare:

1. $\sigma(A^{-1}) = \left\{ \frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_n} \right\};$
2. $\sigma(A - \mu I_n) = \{ \lambda_i - \mu \}, \forall \mu \in \mathbb{R};$
3. $\sigma(A^k) = \{ \lambda_i^k \}, \forall k \in \mathbb{N};$
4. $\sigma((A - \mu I_n)^{-1}) = \left\{ \frac{1}{\lambda_i - \mu} \right\}, \forall \mu \in \mathbb{R}.$

3. Calculați valorile și vectorii proprii ai unui reflector Householder.

Indicație: $G^T u = e_1 G$ - este un reflector. Coloanele lui G sunt vectori proprii.

4. Pentru matricea:

$$A = \begin{bmatrix} c & -s \\ s & c \end{bmatrix} \in \mathbb{R}^{2 \times 2}, \quad c^2 + s^2 = 1,$$

calculați valorile și vectorii proprii.